[Pap] Papoulis A., *Probability, Random Variables and Stochastic Processes*, 3-rd Edition, McGraw Hill International Editions, 1991

[Pro] Proakis J.G., Rader C., Ling F., Nikias C., *Advanced Digital Siganl Processing*, Macmillan Publishing Company, New York, , 1992

[Rab] Rabiner L.R., Schaefer L.W., *Digital Processing of Speech Signal*, Englewood Cliffs, Prentice Hall, 1978

Lucrarea 3
PREDICȚIA LINIARĂ

3.1 Predicția liniară antegradă. Filtrul de eroare a predicției antegrade

Fie $x(n)$ un proces aleator staționar. Se dorește estimarea valorii procesului la momentul n pe baza unui număr finit M de observații (eșantioane) consecutive anterioare. În cazul general valoarea estimată se notează

$$\hat{x}(n)\Big|_{U_M^x(n-p)} \tag{3.1}$$

unde $$U_M^x(n-p)=\{x(n-p-M+1),\ \ldots\ x(n-p)\};\ \ p\geq 1. \tag{3.2}$$

Se spune astfel că s-a realizat ***predicția antegradă cu p pași, de ordinul M***, a eșantionului $x(n)$. Prezintă o importanță deosebită ***predicția liniară antegradă, cu un pas, de ordinul M***, motiv pentru care ***numai*** acest caz particular va fi tratat în continuare. Pentru comoditatea exprimării, atunci când nu sunt posibile confuzii, se va folosi pe scurt numele de predicție, celelalte caracteristici urmând a fi subînțelese. Astfel, estimatul eșantionului $x(n)$ este o combinație liniară a M eșantioane consecutive imediat anterioare

$$\hat{x}(n)\Big|_{U_M^x(n-1)} \overset{Not}{=} \hat{x}(n) = \left(x * h_M^f\right)(n) = \\ =\sum_{i=1}^{M}\left(w_{M,i}^f\right)^* \cdot x(n-i) = \mathbf{W}_M^{fH}\cdot\mathbf{X}(n-1), \tag{3.3}$$

unde $$\mathbf{W}_M^f \overset{Not}{=}\left[w_{M,1}^f \ \ . \ \ . \ \ w_{M,M}^f\right]^T, \tag{3.4}$$

se numește ***vectorul coeficienților de predicție***

$$\mathbf{X}(n)\overset{Not}{=}\left[x(n) \ \ x(n-1) \ \ . \ \ . \ \ x(n-M+1)\right]^T, \tag{3.5}$$

iar $$h_M^f(n) = \sum_{i=1}^{M} w_{M,i}^{f\,*}\cdot\delta(n-i) \tag{3.6}$$

este funcția pondere a filtrului de predicție antegradă. Operatorul $(\ )^H$ este echivalent cu compunerea operațiilor de conjugare și transpunere

$$(\forall)\text{matricea } \mathbf{A}, \qquad (\mathbf{A})^H = \left((\mathbf{A})^*\right)^{\mathrm{T}} = \left((\mathbf{A})^{\mathrm{T}}\right)^*. \tag{3.7}$$

Pentru a evalua precizia estimării se construiește o funcție de cost. Ca și în cazul filtrării optimale ea poate fi de tip medie pătratică (MS). Pentru aceasta se definește, mai întâi, eroarea de predicție

$$f_M(n) \overset{Def}{=} x(n) - \hat{x}(n) = \\ = x(n) - \sum_{i=1}^{M} \left(w_{M,i}^f\right)^* \cdot x(n-i) = \mathbf{a}_M^H \cdot \begin{bmatrix} x(n) \\ \mathbf{X}(n-1) \end{bmatrix}, \tag{3.8}$$

unde $$\mathbf{a}_M \overset{Not}{=} \begin{bmatrix} a_{M,0} & a_{M,1} & . & . & a_{M,M} \end{bmatrix}^{\mathrm{T}} = \begin{bmatrix} 1 \\ -\mathbf{W}_M^f \end{bmatrix}, \tag{3.9}$$

în care $$a_{M,0} = 1 \tag{3.10}$$

și $$a_{M,i} = -w_{M,i}^f \quad \text{pentru } 1 \le i \le M. \tag{3.11}$$

Cu ajutorul ei se formează funcția de cost

$$J_M^f \overset{Def}{=} E\left\{ \left| f(n) \right|^2 \right\}. \tag{3.12}$$

Sistemul care are ca intrare semnalul $x(n)$ și ca ieșire $f(n)$ se numește ***filtru de eroare a predicției*** și poate avea structura din figura de mai jos.

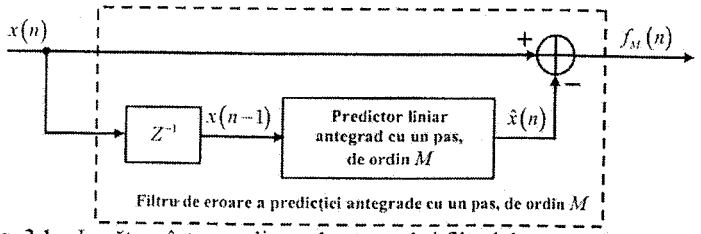


Fig. 3.1. Legătura între predictorul antegrad și filtrul de eroare (a predicției)

În cele mai multe aplicații utilizatorul este interesat direct de eroarea de predicție fără a avea nevoie să cunoască explicit estimatul $\hat{x}(n)$. Din acest motiv, în continuare accentul va fi pus pe studiul erorii, ca mărime de ieșire a ansamblului de predicție

$$f_M(n) = \sum_{i=0}^{M} a_{M,i}^* \cdot x(n-i). \tag{3.13}$$

În acest context $\mathbf{a}_M$ poartă numele de ***vectorul coeficienților filtrului de eroare a predicției antegrade.***

Predicția este optimă în sens MS dacă funcția de cost, calculată conform relației (3.12) este minimă [Pap],[Hay]. Determinarea vectorului optim al coeficienților de predicție se poate reduce la o problemă de filtrare FIR optimală, dacă se fac echivalările prezentate în Tabelul 4.1.[Hay][Ne1][Cio]

Tabelul.3.1

Corespondențe Filtru Wiener – Predictor liniar antegrad cu un pas, de ordin M

Semnificație	Filtru Wiener	Predictor liniar antegrad, cu un pas, de ordin M
Semnalul de intrare	$\mathbf{X}(n)$	$\mathbf{X}(n-1)$
Semnalul de referință	$d(n)$	$x(n)$
Coeficienții filtrului	$\mathbf{W}$	$\mathbf{W}_M^f$
Matricea de autocorelație a semnalului de intrare	$\mathbf{R}$	$\mathbf{R}_M$
Matricea de intercorelație între semnalul de intrare și semnalul de referință	$\mathbf{P}$	$\mathbf{r}_M^f$
Eroarea de estimare	$e(n)$	$f_M(n)$
Funcția de cost	J	J_M^f
Eroarea minima in sens MS	$J_{\min}$	P_M

În tabelul de mai sus

$$\mathbf{R}_M = E\left\{\mathbf{X}(n-1)\cdot\mathbf{X}^H(n-1)\right\} \overset{stationaritate}{=} E\left\{\mathbf{X}(n)\cdot\mathbf{X}^H(n)\right\} = \mathbf{R}, \tag{3.14}$$

reprezintă în continuare matricea de autocorelație a semnalului de intrare, de data aceasta însă, specificându-se explicit prin M, dimensiunea ei,

iar $$\mathbf{r}_M^f \overset{Def}{=} E\{\mathbf{X}(n-1)\cdot x^*(n)\} = [r(-1) \quad . \quad . \quad r(-M)]^{\mathrm{T}}, \tag{3.15}$$

reprezintă matricea de intercorelație între semnalele de la intrarea predictorului și a filtrului de eroare a predicției.

În aceste condiții, soluția optimă corespunzătoare minimului funcției de cost trebuie să satisfacă ecuația matricială Wiener-Hopf [Hay], [Ne1],[Cio]

$$\mathbf{R}_M \cdot \mathbf{W}_M^{f\,0} = \mathbf{r}_M^f, \tag{3.16}$$

în care

$$\mathbf{W}_M^{f\,0} = \left[w_{M,1}^{f\;\;0} \quad . \quad . \quad w_{M,M}^{f\;\;0} \right]^{\mathrm{T}}, \tag{3.17}$$

este ***vectorul coeficienților optimi de predicție antegradă.***

Valoarea minima a funcției de cost, numită și putere de eroare a predicției, devine

$$J_{M_{\min}}^f \overset{Not}{=} P_M = \sigma_{\mathbf{x}}^2 - \mathbf{r}_M^{f\,H} \cdot \mathbf{R}_M^{-1} \cdot \mathbf{r}_M^f = r(0) - \mathbf{r}_M^{f\,H} \cdot \mathbf{W}_M^{f\,0}. \tag{3.18}$$

Aceste două relații reunite sub o formă matricială compactă, poartă numele *de* ***sistem extins Wiener - Hopf pentru predicția antegradă***

$$\begin{bmatrix} r(0) & \mathbf{r}_M^{f\,H} \\ \mathbf{r}_M^f & \mathbf{R}_M \end{bmatrix} \cdot \begin{bmatrix} 1 \\ -\mathbf{W}_M^{f\,0} \end{bmatrix} = \begin{bmatrix} P_M \\ \mathbf{0} \end{bmatrix}. \tag{3.19}$$

Folosind proprietățile de partiționare a matricii de autocorelație relația de mai sus devine

$$\mathbf{R}_{M+1} \cdot \mathbf{a}_M^0 = \begin{bmatrix} P_M \\ \mathbf{0} \end{bmatrix}. \tag{3.20}$$

3.2 Predicția liniară retrogradă. Filtrul de eroare a predicției retrograde

Estimarea eșantionului $x(n-M-p+1)$ pe baza observațiilor $U_M^x(n)$ se numește ***predicție retrogradă cu p pași, de ordin M.*** Cazul liniar al predicției retrograde cu un pas, exclusiv tratat în continuare, este descris prin ecuația cu diferențe finite

$$\hat{x}(n-M)\Big|_{U_M^x(n)} \overset{Not}{=} \hat{x}(n-M) = (x * h_M^g)(n) = \sum_{i=0}^{M-1} \left(w_{M,j}^g\right)^* \cdot x(n-i) = \mathbf{W}_M^{g\,H} \cdot \mathbf{X}(n), \tag{3.21}$$

unde $$\mathbf{W}_M^g = \left[w_{M,0}^g \quad . \quad . \quad w_{M,M-1}^g \right]^{\mathrm{T}} \tag{3.22}$$

este *vectorul coeficienților de predicție retrogradă*, iar

$$h_M^g(n) = \sum_{i=0}^{M-1} w_{M,i}^{g\,*} \cdot \delta(n-i) \tag{3.23}$$

este funcția pondere a predictorului retrograd.

Filtrul care implementează această ecuație se numește predictor retrograd. Diferența între valoarea reală și cea estimată se numește ***eroare de predicție retrogradă*** și se notează cu

$$g_M(n) \overset{Def}{=} x(n-M) - \hat{x}(n-M) = \sum_{i=0}^{M} b_{M,i}^* \cdot x(n-i) = \mathbf{b}_M^H \cdot \mathbf{X}(n), \tag{3.24}$$

unde $$\mathbf{b}_M = \begin{bmatrix} -\mathbf{W}_M^g \\ 1 \end{bmatrix} = \left[b_{M,0} \quad . \quad . \quad b_{M,M-1} \quad b_{M,M} \right]^{\mathrm{T}}, \tag{3.25}$$

în care $$b_{M,M} = 1. \tag{3.26}$$

iar $$b_{M,i} = -w_{M,i}^g \quad \text{pentru} \quad 0 \le i \le M-1. \tag{3.27}$$

Sistemul care produce acest semnal de eroare va fi studiat în detaliu, și se va numi ***filtru de eroare a predicției retrograde.*** Similar paragrafului precedent $\mathbf{b}_M$ reprezintă ***vectorul coeficienților filtrului de eroare a predicției retrograde.*** Legătura sistemului de eroare a predicției retrograde cu predictorul propriu-zis, este prezentată în figura de mai jos.

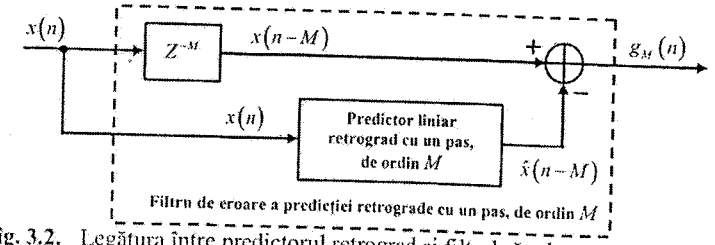


Fig. 3.2. Legătura între predictorul retrograd și filtrul său de eroare a predicției

Măsurarea performanțelor ansamblului de predicție se face prin intermediul funcției de cost

$$J_M^g \overset{Def}{=} E\left\{\left|g_M(n)\right|^2\right\} \tag{3.28}$$

Spunem că filtrul de predicție retrograd este optim în sens MS dacă J_M^g este minimă (puterea secvenței de eroare a predicției retrograde este minimă).

Realizând echivalările din Tabelul 3.2 se obține

Tabelul. 3.2

Corespondențe Filtru Wiener – Predictor liniar retrograd cu un pas, de ordin *M*

Semnificație	Filtru Wiener	Predictor liniar retrograd, cu un pas, de ordin M
Semnalul de intrare	$\mathbf{X}(n)$	$\mathbf{X}(n)$
Semnalul de referință	$d(n)$	$x(n-M)$
Coeficienții filtrului	$\mathbf{W}$	$\mathbf{W}_M^g$
Matricea de autocorelație a semnalului de intrare	$\mathbf{R}$	$\mathbf{R}_M$
Matricea de intercorelație între semnalul de intrare și semnalul de referință	$\mathbf{P}$	$\mathbf{r}_M^g$
Eroarea de estimare	$e(n)$	$g_M(n)$
Funcția de cost	J	J_M^g
Eroarea minima in sens MS	$J_{\min}$	P_M

unde $$\mathbf{r}_M^g = E\left\{\mathbf{X}(n)\cdot x^*(n-M)\right\} = \left[r(M) \quad . \quad . \quad r(1)\right]^{\mathrm{T}} \tag{3.29}$$

este matricea de intercorelație între semnalul de la intrarea predictorului și semnalul prezis.

Cu aceste notații ecuația matricială Wiener-Hopf pentru determinarea soluției optime

$$\mathbf{W}_M^{g\,0} \overset{Not}{=} \left[w_{M,0}^{g\;0} \quad . \quad . \quad w_{M,M-1}^{g\;0}\right]^{\mathrm{T}} \tag{3.30}$$

devine $$\mathbf{R}_M \cdot \mathbf{W}_M^{g\,0} = \mathbf{r}_M^g, \tag{3.31}$$

iar valoarea minimă a funcției de cost, cu semnificație de putere a erorii optime,

$$J_{M_{\min}}^g = \sigma_x^2 - \mathbf{r}_M^{g\,H}\cdot\mathbf{R}_M^{-1}\cdot\mathbf{r}_M^g = r(0) - \mathbf{r}_M^{g\,H}\cdot\mathbf{W}_M^{g\,0} \overset{Not}{=} P_M. \tag{3.32}$$

Ecuațiile (3.31) și (3.32) pot fi de asemenea scrise sub o formă matricia compactă, numită ***sistemul de ecuații Wiener - Hopf extins***

$$\begin{bmatrix}\mathbf{R}_M & \mathbf{r}_M^g\\ \mathbf{r}_M^{g\,H} & r(0)\end{bmatrix}\cdot\begin{bmatrix}-\mathbf{W}_M^{g\,0}\\ 1\end{bmatrix} = \begin{bmatrix}\mathbf{0}\\ J_{M_{\min}}^g\end{bmatrix} \tag{3.33}$$

sau, folosind (3.14), (3.25) și (3.32)

$$\mathbf{R}_{M+1}\cdot\mathbf{b}_M^0 = \begin{bmatrix}\mathbf{0}\\ P_M\end{bmatrix}. \tag{3.34}$$

3.3 Relații între coeficienții predicției antegrade și coeficienții predicției retrograde

Analizând relațiile (3.15) și (3.29) se constată că

$$\mathbf{r}_M^f = \breve{\mathbf{r}}_M^{g\,*} \tag{3.35}$$

în care $\breve{}$ semnifica faptul că elementele matricii sunt scrise în ordine inversă.

Atunci, soluția optimă $\mathbf{W}_M^{g\,0}$ pentru predictorul retrograd trebuie să satisfacă relația

$$\mathbf{R}_M^{\mathrm{T}}\cdot\breve{\mathbf{W}}_M^{g\,0} = \mathbf{r}_M^{f\,*}, \tag{3.36}$$

de unde prin conjugare și comparare cu (3.16) se obține rezultatul important

$$\breve{\mathbf{W}}_M^{g\,0\,*} = \mathbf{W}_M^{f\,0}. \tag{3.37}$$

Observația 3-1

O relație similară este valabilă și între vectorii coeficienților optimi pentru filtrele de eroare a predicției

$$\breve{\mathbf{b}}_M^{0\,*} = \mathbf{a}_M^0, \tag{3.38}$$

sau explicit

$$\left[b_{M,M}^{0*} \quad . \quad . \quad b_{M,1}^{0*} \quad b_{M,0}^{0*}\right]^{\mathrm{T}} = \left[a_{M,0}^0 \quad . \quad . \quad a_{M,M-1}^0 \quad a_{M,M}^0\right]^{\mathrm{T}}. \tag{3.39}$$

Observația 3-2

Se poate modifica un predictor antegrad într-unul retrograd prin conjugarea coeficienților de predicție și plasarea lor în ordine inversă

O consecință a relațiilor (3.35) și (3.37) este

$$J^{g}_{M_{\min}} = \sigma_x^2 - \mathbf{r}_M^{g\,H} \cdot \mathbf{W}_M^{g\,0} = \\ = \sigma_x^2 - \mathbf{r}_M^{f\,H} \cdot \mathbf{W}_M^{f\,0} = J^{f}_{M_{\min}} \overset{Not}{=} P_M \tag{3.40}$$

deci ***puterile secvențelor de eroare a predicției antegrade și retrograde sunt egale dacă predicția este optimă*** în sens MS. Acesta este motivul pentru care s-a folosit cu anticipație **aceeași notație** P_M .pentru minimele ambelor funcții de cost. O formă echivalentă pentru puterea erorii, formă ce își va dovedi ulterior utilitatea, este

$$P_M = \sum_{i=0}^{M} r(i) \cdot a^0_{M,i} = \sum_{i=0}^{M} r(-i) \cdot b^0_{M,M-i} \tag{3.41}$$

3.4 Implementarea filtrelor FIR de eroare a predicției

Pentru filtrele FIR de eroare a predicției sunt uzuale implementările care folosesc două tipuri de structuri - transversale și latice. Fiecare din acestea prezintă avantaje și dezavantaje specifice. Totuși de cele mai multe ori, în cazurile în care este necesar numai calculul erorii de predicție, (nu și al eșantionului prezis) se preferă structura de tip latice. Așa cum se va demonstra ulterior ea permite calculul simultan atât al erorii predicției antegrade cât și al erorii predicției retrograde.

3.4.1 Structura transversală pentru filtrele FIR de eroare a predicției

În figura Fig. 3.3. este prezentat graful de semnal pentru un filtru de eroare a predicției implementat într-o structură transversală.

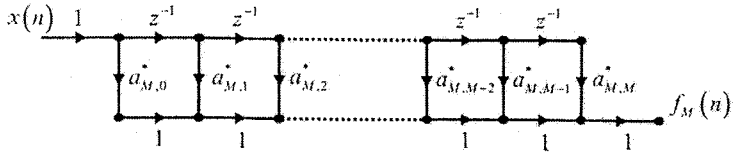


Fig. 3.3. Structura transversală pentru filtrul de eroare a predicției antegrade

Pentru acest tip de structură, coeficienții sunt chiar elementele funcției pondere iar eroarea de predicție antegradă poate fi calculată cu ajutorul expresiei

$$f_M(n) = \sum_{j=0}^{M} a^*_{M,j} \cdot x(n-j). \tag{3.42}$$

Similar, pentru filtrul de eroare a predicției retrograde, a cărui implementare transversală este prezentată în Fig. 3.4., semnalul la ieșire (eroarea) poate fi obținut cu ajutorul; relației

$$g_M(n) = \sum_{j=0}^{M} b^*_{M,j} \cdot x(n-j). \tag{3.43}$$

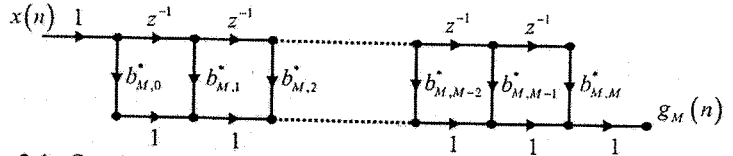


Fig. 3.4. Structura transversală pentru filtrul FIR de eroare a predicției retrograde

3.4.2 Structura latice pentru filtrele FIR de eroare a predicției

Considerăm structura latice pentru filtre FIR, structură prezentată în Fig. 3.5.

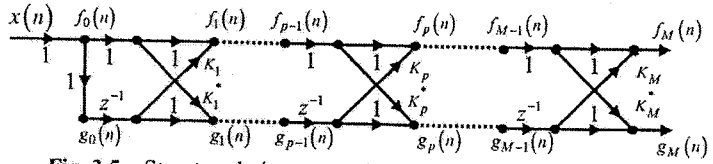


Fig. 3.5. Structura latice pentru filtrul FIR de eroare al predicției

Filtrul prezintă o singură intrare $x(n)$ și două ieșiri $f_M(n)$, și $g_M(n)$. Etajul p al acestei structuri este caracterizat de ecuațiile cu diferențe finite:

$$f_0(n) = g_0(n) = x(n), \tag{3.44}$$

$$f_p(n) = f_{p-1}(n) + K_p \cdot g_{p-1}(n-1) \quad \text{pentru } p = \overline{1, M}, \tag{3.45}$$

$$g_p(n) = K_p^* \cdot f_{p-1}(n) + g_{p-1}(n-1) \quad \text{pentru } p = \overline{1, M}. \tag{3.46}$$

Utilizarea transformării $\mathcal{Z}$ permite scrierea acestor ecuații în forma

**
$$F_p(z) = F_{p-1}(z) + K_p \cdot z^{-1} \cdot G_{p-1}(z), \tag{3.47}$$

***
$$G_p(z) = K_p^* \cdot F_{p-1}(z) + z^{-1} \cdot G_{p-1}(z), \tag{3.48}$$

sau matricial, pentru $p = \overline{1, M}$

$$\begin{bmatrix} F_p(z) \\ G_p(z) \end{bmatrix} = \begin{bmatrix} 1 & z^{-1} \cdot K_p \\ K_p^* & z^{-1} \end{bmatrix} \cdot \begin{bmatrix} F_{p-1}(z) \\ G_{p-1}(z) \end{bmatrix} = \begin{bmatrix} 1 & K_p \\ K_p^* & 1 \end{bmatrix} \cdot \begin{bmatrix} F_{p-1}(z) \\ z^{-1} \cdot G_{p-1}(z) \end{bmatrix}, \tag{3.49}$$

unde
$$F_0(z) = G_0(z) = X(z) \tag{3.50}$$

Structura latice prezintă unele avantaje datorate în special relației care există între ieșirile $f_M(n)$ și $g_M(n)$. Pentru a evidenția acest lucru se poate demonstra că pentru condițiile la limită $F_0(z) = G_0(z) = X(z)$ se respectă relațiile recurente

$$H_p^f(z) = H_{p-1}^f(z) + K_p \cdot z^{-1} \cdot H_{p-1}^g(z), \tag{3.51}$$

$$H_p^g(z) = z^{-p} \cdot H_p^{f(*)}(z^{-1}), \tag{3.52}$$

în care

$$H_p^f(z) = \frac{F_p(z)}{X(z)}, \tag{3.53}$$

reprezintă funcția de transfer de la intrare la ieșirea $f_p(n)$,

$$H_p^g(z) = \frac{G_p(z)}{X(z)}, \tag{3.54}$$

reprezintă funcția de transfer de la intrare la ieșirea $g_p(n)$, iar operatorul $^{(*)}$ semnifică faptul că se conjugă toți coeficienții K_i în expresia asupra căreia acesta se aplică. Deoarece filtrul este de tip FIR cele două funcții de transfer sunt de forma

$$H_p^f(z) = \sum_{j=0}^{p} \phi_{p,j} \cdot z^{-j}, \tag{3.55}$$

$$H_p^g(z) = \sum_{j=0}^{p} \gamma_{p,j} \cdot z^{-j}. \tag{3.56}$$

Atunci, ținând cont de (3.52), între coeficienții ϕ_j și γ_j există relația

$$\gamma_{p,j} = \phi_{p,p-j}^* \tag{3.57}$$

Observația 3-3

Dacă filtrul este astfel proiectat încât ieșirea $f_M(n)$ să reprezinte eroarea de predicție antegradă atunci $g_M(n)$ va reprezenta eroarea de predicție retrogradă, filtrul calculând simultan ambele erori de predicție. Acesta este unul din motivele pentru care în implementarea filtrelor de eroare a predicției se preferă structura latice.

3.4.3 Algoritmi de conversie între coeficienții structurilor transversale și latice

Se pune acum problema stabilirii unei corespondențe între coeficienții structurii latice și cei ai formei canonice (transversale). Trecerea structură latice → structură transversală se obține imediat din (3.57) conform algoritmului de mai jos.

Algoritm conversie latice >> transversal

1. Inițializări.

$\{\phi_{0,0} = 1$

$\gamma_{0,0} = 1\}$

2. pentru $p = 1, M$

$\{\phi_{p,0} = \phi_{p-1,0}$

pentru $j = 1, p-1$

$\{\phi_{p,j} = \phi_{p-1,j} + K_p \cdot \gamma_{p-1,j-1}\}$

$\phi_{p,p} = K_p \cdot \gamma_{p-1,p-1}$

pentru $j = 0, p$

$\{\gamma_{p,j} = \phi_{p,p-j}^*\}$

}

3. pentru $j = 0, M$

$\{a_{M,j} = \phi_{M,j}^*$

$b_{M,j} = \gamma_{M,j}^*\}$

Pentru a exprima coeficienții structurii latice în funcție de cei ai structurii transversale pentru filtrul de eroare, se prelucrează mai întâi ecuația (3.49) de unde, prin inversare, se obține

$$\begin{bmatrix} F_{p-1}(z) \\ z^{-1}\cdot G_{p-1}(z) \end{bmatrix} = \frac{1}{1-|K_p|^2}\cdot\begin{bmatrix} 1 & -K_p \\ -K_p^* & 1 \end{bmatrix}\cdot\begin{bmatrix} F_p(z) \\ G_p(z) \end{bmatrix}. \qquad (3.58)$$

Rezultă următorul algoritm:

Algoritm conversie transversal >> latice

1. Inițializări

{**pentru** $j=0, M$

$\{\phi_{M,j} = a^*_{M,j}$

$\gamma_{M,M-j} = a_{M,j}\}$

$K_M = \phi_{M,M}\}$

2. pentru $p = M-1, 1$

{**pentru** $j = 1, p$

$\{\phi_{p,j} = \frac{1}{1-|K_{p+1}|^2}\cdot\left(\phi_{p+1,j} - K_{p+1}\cdot\gamma_{p+1,j}\right)$

$\gamma_{p,p-j} = \phi^*_{p,j}\}$

$K_p = \phi_{p,p}\}$

Algoritmul prezentat pornește de la coeficienții filtrului de eroare a predicției antegrade. Pentru a obține un algoritm bazat pe coeficienții filtrului de eroare a predicției retrograde se înlocuiește secțiunea 1 cu

1. Inițializări

{**pentru** $j=0, M$

$\{\gamma_{M,j} = b^*_{M,j}$

$\phi_{M,M-j} = b_{M,j}\}$

$K_M = \phi_{M,M}\}$

Se observă că structura latice permite o reprezentare mai convenabilă, proiectarea unui filtru optim cu un ordin mai mare cu o unitate implică doar adăugarea unui etaj

suplimentar cu parametrii adecvați. Spre deosebire, în cazul creșterii cu o unitate ordinului filtrelor transversale este necesar calculul întregului set de coeficienți (pentr toate etajele).

3.5 Desfășurarea lucrării

1. Înregistrați în format "wav", într-un singur fișier, fonemele "a", "e", "i", "o", "u" Se va utiliza pentru frecvența de eșantionare valoarea 8Khz iar cuantizarea se v realiza pe 16 biți.

   Pentru realizarea achiziției semnalului vocal recomandăm configurația dir Fig. 3.5.

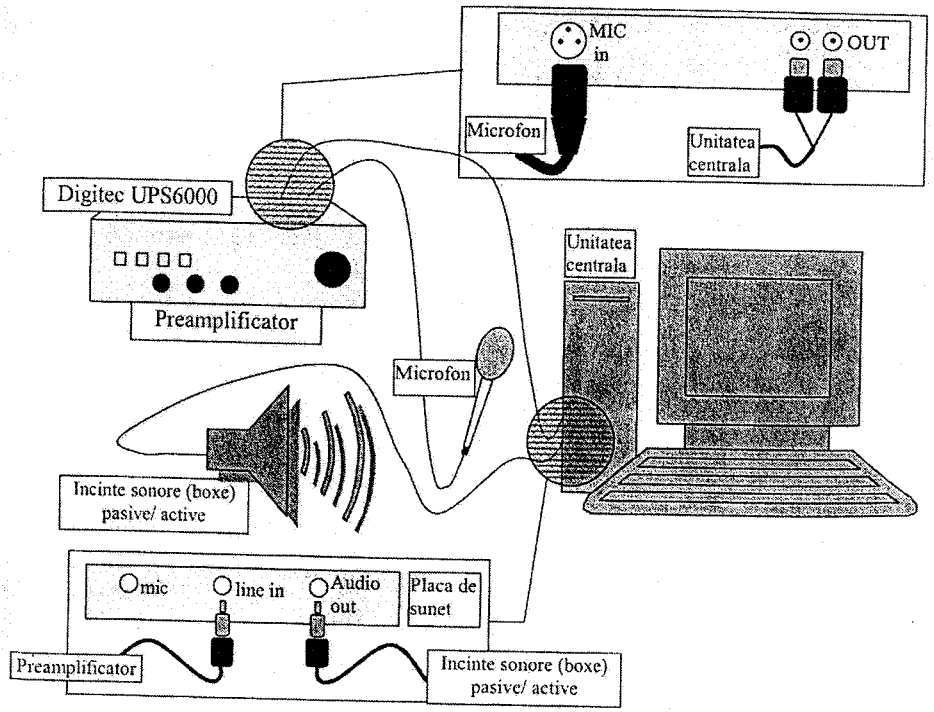


Fig. 3.6. Achiziția semnalului vocal

Se va folosi intrarea „line-in" a plăcii de sunet a calculatorului și se va selecta, în prealabil, opțiunea „line-in" din panoul „Volume Controls – Recording". Se va acorda o atenție deosebită reglării volumul intrării astfel încât înregistrarea să aibă loc cu un volum suficient de mare pentru a menține raportul semnal zgomot la

nivele acceptabile, dar ***să nu se producă limitarea semnalului.*** Înregistrarea propriu-zisă se poate realiza folosind aplicația „Sound Recorder" din Windows. Înainte de fiecare nouă achiziție se vor seta/verifica parametrii pentru cuantizarea și eșantionarea semnalului analogic (PCM, 8kHz, 16 biți, mono).

2. Folosind funcția "wavread" introduceți în mediul Matlab semnalul înregistrat obținând astfel semnalul de intrare ($x(n)$). Vizualizați grafic, audiați (vezi funcția "sound") și izolați (prin determinarea limitelor pentru m) fiecare fonem. Selectați prin fixarea parametrului m câte un cadru de lungime N=220 eșantioane din fiecare fonem (Atenție! Alegeți m astfel încât cadrul să cuprindă numai eșantioanele aceluiași fonem).
3. Luați în considerare fonemul "a" (fixați m).
4. Calculați ${}^1r(\lambda,m)$ pentru domeniul $\lambda=\overline{0,14}$
5. Folosind ${}^1r(\lambda,m)$, determinați coeficienții pondere pentru filtrele de eroare a predicției antegrade (**a**) și retrograde (**b**) rezolvând direct sistemul de ecuații Wiener Hopf. Considerați $M=8$. Studiați legătura între coeficienții **a** și **b**.
6. Determinați și reprezentați în planul **Z**, poziția nulurilor filtrelor de eroare a predicției. Comentați.
7. Implementați filtrele de eroare a predicției considerând $M=8$. Implementările se vor realiza pentru structura transversală.
8. Obțineți semnalele $f_M(n)$ și $g_M(n)$, pentru $n\in\overline{m-N+1,\,m}$, considerând pentru filtrele de eroare a predicției, stare inițială nulă.
9. Reprezentați grafic într-o aceeași fereastră (dar pe grafice diferite), $x(n)$, $f_M(n)$ și $g_M(n)$, pentru $n\in\overline{m-N+1,\,m}$ (vezi "funcția subplot"). Comentați.
10. Reprezentați grafic, într-o aceeași fereastră, ${}^3r_x(\lambda,m)\,/\,{}^3r_x(0,m)$ și ${}^3r_{f_M}(\lambda,m)/{}^3r_{f_M}(0,m)$ pentru domeniul $\lambda=\overline{0,\,N-1}$; (vezi "funcția subplot"). Comentați.
11. Implementați sistemul de sinteză (reconstrucția semnalului folosind eroarea de predicție și coeficienții **a**). Considerați că starea inițială este nulă. Comparați semnalul sintetizat $y(n)$ cu semnalul original $x(n)$.
12. Calculați și reprezentați, folosind aceeași scală și același domeniu de reprezentare $|X(\omega)|$, $|F_M(\omega)|$, $|1/H_M^f(\omega)|$. Pentru ordonată se va folosi scara logaritmic (vezi funcția "semilogy"). Comentați.
13. Calculați puterea semnalului de eroare a predicției (P_M). Reprezentați, pentr domeniul $M=\overline{6,14}$, dependența P_M -ordin de predicție (M). Comentați.
14. Determinați coeficienții K (din structura latice) folosind algoritmul de trecer transversal >> latice și ponderile **a** și **b** pentru ordinul $M=8$. Comentați.
15. Selectați succesiv fonemele "a" "e", "i", "o", "u" și reluați, pentru fiecare fonem în parte punctele 4-10. Comentați.
16. Pentru fiecare dintre foneme reprezentați grafic și studiați comparativ semnalele $f_M(n)$, pentru $M=8$. Comentați.
17. Pentru fiecare dintre foneme, reprezentați ${}^3r_x(\lambda,m)\,/\,{}^3r_x(0,m)$ pentru domeniu $\lambda=\overline{0,\,N}$ și $M=8$. Determinați din acest grafic T_0 (F_0).
18. Pentru fiecare dintre foneme, reprezentați ${}^3r_{f_M}(\lambda,m)\,/\,{}^3r_{f_M}(0,m)$ pentru domeniul $\lambda=\overline{0,\,N}$ și $M=8$. Determinați din acest grafic T_0 (F_0). Comentați.

Bibliografie

[Boi] Boite R., Bourlard H., Dutoit T., Hancq J., Leich, *Traitement de la parole*, 3-rd Edition, Presses Polytechniques et Universitaires Romandes, 2000

[Cra] Cramer H., Leadbetter M.R., *Stationary and Related Stochastic Processes*, John Wiley, 1967

[Cio] Ciochină S., Negrescu C., *Sisteme Adaptive*, Editura Tehnică, București, 1999

[Hay] Haykin S., *Adaptive Filter Theory*, Third Edition, Prentice Hall International, Inc. Englewood Cliffs, 1996

[Ne1] Negrescu C., *Bazele algoritmilor adaptive de gradient. Metode de optimizare*, Litografia U.P.B., București, 1997

[Ne2] Negrescu C., *Prelucrarea semnalului vocal în comunicații mobile*, Note de curs.

[Ne3] Negrescu C., *Codarea și compresia semnalului audio*, Note de curs.